

ANTEPROYECTO DEL TRABAJO DE FIN DE MÁSTER

INFORMACIÓN GENERAL

Alumno/a	Antonio Navajas Ortega				
Titulación:	Máster Universitario en Ingeniería del Software e Inteligencia Artificial				
Tutor/es:	Ezequiel López Rubio Miguel Ángel Molina Cabello				
Título	Super-resolución de imágenes citogenéticas mediante modelos de difusión				
Subtítulo <i>(solo si es Colaborativo)</i>					
Título en inglés	Cytogenetic images super-resolution using diffusion models				
Subtítulo en inglés <i>(solo si es Colaborativo)</i>					
Trabajo colaborativo:	Sí	☐	No	☒	
Otros integrantes del grupo:					
Idioma de la memoria y defensa:	Castellano	☒	Inglés	☐	

INTRODUCCIÓN

Contextualización del problema a resolver. Descripción detallada de la motivación de este TFM y el dominio de aplicación.

El análisis de imágenes de cromosomas es una tarea central en citogenética y biología molecular, ya que los cromosomas contienen el ADN que codifica la información genética de un organismo. Alteraciones en su número o estructura pueden causar enfermedades genéticas como el síndrome de Down (trisomía 21), el síndrome de Turner (monosomía X) o ciertos tipos de cáncer derivados de translocaciones o deleciones cromosómicas. Por ello, su estudio es fundamental en el diagnóstico clínico, prenatal y en la investigación genética. Además, el análisis cromosómico permite evaluar la estabilidad genómica, identificar marcadores citogenéticos y apoyar decisiones terapéuticas en contextos oncológicos y reproductivos.

Sin embargo, los cromosomas presentan un alto grado de complejidad: son visualmente similares entre sí, varían en tamaño, forma y patrón de bandas, y su análisis manual bajo microscopio es lento, propenso a errores y requiere personal altamente especializado. A esto se suma la variabilidad introducida por las condiciones de preparación de las muestras y por los dispositivos de adquisición, lo que puede afectar la calidad y homogeneidad de las imágenes obtenidas. Estos factores limitan la rapidez, consistencia y escalabilidad del análisis tradicional, dificultando el cribado masivo de muestras y el estudio detallado de anomalías estructurales.

La automatización mediante inteligencia artificial (IA) y visión computacional ofrece soluciones significativas. Algoritmos de aprendizaje profundo del estado del arte, como redes neuronales convolucionales y modelos de difusión, permiten aprender representaciones directamente a partir de los datos, identificando patrones espaciales complejos que resultan difíciles de definir mediante métodos convencionales. Estos enfoques posibilitan la clasificación automática de cromosomas, la detección de anomalías y la cuantificación de patrones de bandas de forma precisa y consistente, reduciendo errores humanos y aumentando la eficiencia del análisis. Esto no solo acelera los procesos clínicos y de investigación, sino que también habilita la detección temprana de alteraciones genéticas y el análisis de grandes volúmenes

de datos cromosómicos.

Además, la aplicación de técnicas de super-resolución y modelos avanzados de difusión contribuye a mejorar la calidad visual de las imágenes, permitiendo reconstruir detalles finos esenciales para el análisis automatizado. La mejora en la resolución puede resultar determinante cuando se trata de identificar pequeñas variaciones estructurales o patrones de bandas sutiles. Esto amplía el potencial de la investigación, facilitando estudios más precisos sobre la estructura y función del genoma, así como la evolución genética, y abre la puerta a descubrimientos científicos más rápidos y rigurosos.

OBJETIVOS

Descripción detallada de este TFM. Preguntas de investigación a abordar (si procede).

El objetivo principal de este TFM es estudiar si los modelos de difusión pueden mejorar la resolución de imágenes citogenéticas, preservando los detalles estructurales importantes para el análisis cromosómico y el diagnóstico asistido por sistemas automáticos. De forma concreta, se pretende:

1. Desarrollar un sistema eficaz para la mejora de resolución de imágenes citogenéticas que maximice la precisión visual mientras se preserva la integridad de los detalles relevantes.
2. Evaluar si esta mejora se traduce en un mayor rendimiento de detección automática de cromosomas.
3. Explorar distintas configuraciones y ajustes de StableSR para optimizar la calidad de reconstrucción.

Se hará especial hincapié en la fidelidad estructural y la utilidad funcional de las imágenes, mientras que la eficiencia computacional tendrá un carácter secundario, dado que el procesamiento no requiere tiempo real.

ENTREGABLES

Listado de resultados que generará el TFM (aplicaciones, estudios, manuales, etc.)

Código de las implementaciones desarrolladas

Memoria

MÉTODOS Y FASES DE TRABAJO

METODOLOGÍA:

Descripción de la metodología empleada en el desarrollo del TFM. Especificar cómo se va a desarrollar. Concretar si se trata de alguna metodología existente. En caso contrario, describir y justificar adecuadamente los métodos que se aplicarán.

El desarrollo de este proyecto se llevará a cabo mediante una metodología ágil, que permitirá flexibilidad y adaptación en cada fase del trabajo. Se adoptará un enfoque iterativo, de manera que el modelo pueda ajustarse de forma continua en función de los resultados obtenidos en ejecuciones previas. Para garantizar la validez del proceso y reducir el riesgo de sobreajuste, el modelo se entrenará utilizando validación cruzada.

El proyecto partirá de una versión base del sistema, a la cual se irán incorporando mejoras de manera incremental, sin comprometer la estructura existente. Este enfoque facilita una rápida adaptación frente a imprevistos técnicos y optimiza la eficiencia en el desarrollo.

Paralelamente, se seguirán las buenas prácticas del método científico, que incluyen: observación, formulación de hipótesis,

revisión de literatura, experimentación, análisis de resultados, elaboración de conclusiones y comunicación de los hallazgos. La combinación de un enfoque ágil con el rigor científico asegura que el proyecto avance de manera estructurada, eficiente y reproducible.

FASES DE TRABAJO:

Enumeración y breve descripción de las fases de trabajo para el desarrollo del TFM.

Durante el desarrollo del proyecto se llevarán a cabo las siguientes fases:

1. Revisión bibliográfica y análisis de trabajos previos: Se realizará un estudio detallado de la literatura relacionada con super-resolución de imágenes biomédicas, modelos de difusión y detección de objetivos en imágenes relacionadas con histología y/o citológicas. Esto permitirá establecer las bases teóricas y matemáticas, así como identificar enfoques exitosos aplicables a imágenes citogenéticas.
2. Preparación del entorno de trabajo: Configuración del entorno de desarrollo, instalación de dependencias y comprobación del correcto funcionamiento de las herramientas necesarias para el procesamiento de imágenes, entrenamiento de modelo de difusión StableSR y evaluación con YOLO11.
3. Análisis de algoritmos y del conjunto de datos: Se llevará a cabo un análisis detallado del conjunto de imágenes con el fin de definir estrategias adecuadas de preprocesamiento y aumento de datos. Paralelamente, se realizará un estudio del funcionamiento interno de YOLO11, así como de los componentes de difusión, como el noise scheduler, el sampling, la red U-Net y los mecanismos de pérdida, con el objetivo de comprender y modificar el proceso de difusión para optimizar la reconstrucción de detalles cromosómicos.
4. Implementación de la línea base: Se establecerá un modelo base YOLO11 con finetuning usando las imágenes a resolución original, para poder comparar posteriormente la posible mejora al aplicar superresolución a las imágenes de validación.
5. Iteraciones experimentales con modelos de difusión: A partir de la línea base, se explorarán diferentes configuraciones para mejorar la super-resolución, incluyendo:
 1. Ajustes en noise schedulers y métodos de sampling deterministas vs. estocásticos.
 2. Posible incorporación de Fourier features o modificación de funciones de pérdida.
 3. Variaciones en parámetros de StableSR o en su arquitectura.

Cada iteración conlleva su validación cruzada correspondiente.

6. Se evaluará el rendimiento del modelo comparando los resultados obtenidos sobre imágenes con super-resolución frente a las originales, utilizando métricas de calidad de imagen (PSNR, SSIM) y métricas de detección (mAP, precisión, recall y F1-score).
7. Análisis de resultados: Se comentarán los patrones y tendencias observadas en las imágenes tras cada iteración de super-resolución, verificando si la visibilidad de detalles cromosómicos y la detección automática han mejorado o empeorado. Se analizarán los retos encontrados, se formularán hipótesis sobre el rendimiento de distintos modelos y se identificarán los conceptos más importantes, así como las posibles oportunidades de optimización.
8. Documentación y comunicación de resultados: Redacción de la memoria final, incluyendo metodología, resultados, análisis comparativo entre configuraciones, conclusiones y posibles líneas futuras de investigación.

ENTORNO TECNOLÓGICO

TECNOLOGÍAS EMPLEADAS:

Enumeración de las tecnologías utilizadas (lenguajes de programación, frameworks, sistemas gestores de bases de datos, etc.) en el desarrollo del TFM.

Lenguaje de programación: Python 3.10

Tecnologías principales: Ultralytics YOLO11, StableSR, Overleaf, FileZilla, X2Go

Otras dependencias: PyTorch, Scikit-learn, Numpy, Pillow, Matplotlib, OpenCV, Torchvision, Xformers, Transformers

RECURSOS SOFTWARE Y HARDWARE:

Listado de dispositivos (placas de desarrollo, microcontroladores, procesadores, sensores, robots, etc.) o software (IDE, editores, etc.) empleados en el desarrollo del TFM.

IDE: Visual Studio Code

Gestor de Entorno Virtual: Anaconda

Máquina de Ejecución 1: Servidor Grupo Investigación ICAI con GPU RTX 3080 10 GB VRAM

Máquina de Ejecución 2: Computador Personal con GPU RTX 5060 8 GB VRAM

CONJUNTOS DE DATOS (DATASETS):

Listado de los conjuntos de datos (datasets) que serán empleados en el desarrollo del TFM (si procede), detallando en su caso su procedencia y licencia de uso.

Para el entrenamiento y la validación se utilizarán conjuntos de datos privados proporcionados por el grupo de investigación ICAI, en colaboración con el Dr. Adayabalam S. Balajee (REAC/TS, ORISE, Tennessee, EE. UU.). El conjunto de datos consta de 50 imágenes de resolución variable que muestran cromosomas en blanco y negro, algunas de las cuales presentan artefactos de forma circular.

REFERENCIAS

Listado de referencias (artículos científicos, libros, páginas web, etc.)

[1] Rahima Khanam et al. (2024). [\[2410.17725v1\] YOLOv11: An Overview of the Key Architectural Enhancements](#)

[2] Ultralytics Team. (2024) [Ultralytics YOLO11 - Ultralytics YOLO Docs](#)

[3] Jianyi Wang et al. (2023). [\[2305.07015\] Exploiting Diffusion Prior for Real-World Image Super-Resolution](#)

[4] Ignacio Atencia Jiménez et al. (2024). [Neural Network Ensemble to Detect Dcentric Chromosomes in Metaphase Images](#)

[5] L. Antiga, E. Stevens and T. Viehmann. (2020). Deep Learning with Pytorch. New York: Manning Publications Co. LLC.

[6] Harshith Bachimanchi et al. (2024). [\[2409.16488\] Diffusion Models to Enhance the Resolution of Microscopy Images: A Tutorial](#)

Málaga, 19 de Febrero de 2026

Firma tutor/tutora:

LOPEZ
RUBIO

EZEQUIEL - 53151817J
Fecha: 2026.02.19
21:19:56 +01'00'

Firma cotutor/a:

MOLINA
CABELLO
MIGUEL

ANGEL - 50603096Z
Fecha: 2026.02.20
00:28:09 +01'00'